

Rapport de stage

**Révolution OMICS :
Intégration Multi-dimensionnelle et Nouveaux Horizons pour
une Médecine Personnalisée des Cancers**

-

Jordan Dutel

Encadré par

Youenn Drouet

-

**Biostatisticien, Data Scientist (PhD)
Département Prévention et Santé Publique
Centre Léon Bérard**

Année 2023 / 2024

Résumé

L'intégration de données multi-omiques en recherche médicale permet aujourd'hui de proposer aux patients atteints de cancer une médecine personnalisée à leur profil moléculaire et des thérapies ciblées contre leur tumeur. C'est dans ce cadre que s'inscrit l'étude de la cohorte ImmunoProfiler et que, grâce à la technique non supervisée d'analyse factorielle des données multi-omiques, MOFA, nous avons pu caractériser l'ensemble des patients afin de détecter des potentielles corrélations entre les proportions de cellules immunitaires au sein de ces tumeurs et le profil mutationnel et génétique des patients selon plusieurs types tumoraux. Nous avons été capables de résumer une très grande partie de la variance totale des multiples données initialement comprises dans plus de 200 variables explicatives, en seulement 15 facteurs latents. Ces derniers ont notamment permis de catégoriser les 483 patients de la cohorte ImmunoProfiler en 9 clusters. En plus de s'avérer particulièrement utiles pour les biologistes et le corps médical pour classer les potentiels patients à risque selon leur type de cancer, ces clusters tendent à montrer que les variables génétiques et immunologiques ne sont fondamentalement pas différentes selon le type tumoral considéré, et donc orientent vers une vision dite « pan cancer ».

Mots-Clés : Statistiques multivariées ; Analyse factorielle ; Données multi-omics ; MOFA ; Médecine personnalisée ; ImmunoProfiler ; Cancer

Table of Contents

I. Introduction.....	5
II. Matériel et méthodes.....	6
A. Cohorte ImmunoProfiler.....	6
B. Génération de profils mutationnels.....	6
C. Analyses intégratives multi-omics.....	6
D. Prétraitement des données génomiques.....	7
E. Prétraitement des données immunologiques.....	7
F. Flowchart.....	8
III. Résultats.....	9
A. Waterfallplot.....	9
1. Profil mutationnel général.....	9
2. Profil mutationnel spécifique.....	11
a. Cancers digestifs.....	11
b. Cancers ORL.....	13
B. Multi-Omics Factor Analysis.....	15
1. Caractéristiques du modèle entraîné et facteurs latents associés.....	15
2. Caractérisation des facteurs latents.....	17
3. Clusterisation des patients et caractérisation des clusters trouvés.....	20
IV. Discussion.....	22
V. Conclusion.....	23
A. Réponse à la problématique.....	23
B. Ouverture.....	23
1. Recherche de clusters à susceptibilité.....	23
2. Machine Learning.....	23

Table des figures

Noms	Pages
Figure 1 : Transformation logarithmique	7
Figure 2 : Flowchart de l'étude	8
Figure 3 : Profil mutationnel général	9
Figure 4 : Profil mutationnel des cancers digestifs	11
Figure 5 : Profil mutationnel des cancers ORL	13
Figure 6 : Modèle MOFA et variance expliquée	15
Figure 7 : Distribution des valeurs des facteurs latents	17
Figure 8 : Variables contributives et heatmeap des facteurs latents 1 et 2	18
Figure 9 : Tableau des top variables	18
Figure 10 : Clusters et UMAP	20

Liste des abréviations

Abréviations	Définitions
CLB	Centre Léon Bérard
OMS	Organisation Mondiale de la Santé
IARC	International Agency for Research on Cancer
ICI	Immuno-Checkpoint Inhibitors
INCa	Institut National du Cancer
ProfiLER	Profilage Lyric Et Région
ORL	Oto-Rhino-Laryngologique
SNC	Système Nerveux Central
ConSoRe	Continuum Soins Recherche
SNV	Single Nucleotide Variant
CNV	Copy Number Variant
NK	Natural Killer
GenVisR	Genomic Visualizations in R
MOFA	Multi-Omics Factor Analysis
LF [1, 2, 3, ...]	Latent factor [1, 2, 3, ...]
LTCD4/8	Lymphocyte T Cluster of Differentiation 4/8
cDC	Conventional Dendritic Cells

Liste des logiciels

Logiciels	Version
RStudio	2023.12.1.402
Package « GenVisR »	1.34.0
Package « MOFA2 »	1.12.1

I. Introduction

En 2022, selon l'OMS et l'IARC, on comptait 20 millions de nouveaux cas de personnes développant un cancer dans le monde et environ 10 millions de personnes décédant cette même année, positionnant cette maladie comme la 2^e plus importante cause de mortalité dans le monde [1]. C'est donc, de nos jours, un enjeu de santé publique important dans lequel les pays et les institutions investissent largement pour la lutte et la recherche. Il est actuellement reconnu que l'origine du cancer est plurifactorielle et liée à une combinaison de caractéristiques propres à l'individu (biologie) mais aussi externes à la personne (environnement) [2]. Nous savons notamment que parmi les facteurs biologiques impliqués, la génétique contribue énormément à l'origine du cancer. De même, les caractéristiques immunologiques du patient et de la tumeur développée prennent une place prépondérante dans l'apparition de la maladie. Cela a amené la science et la médecine à chercher des cibles pour les thérapies, spécifiques parfois à un type de cancer voire même aux types de tumeur développés par le patient (inhibiteurs MAPkinase pour les cancers colorectaux [3], les ICI pour réactiver les cellules immunitaires (anti-PDL1...) [4], [5]), mais également des biomarqueurs caractéristiques d'un type de cancer voire même d'un type de tumeur permettant de prévenir l'apparition du cancer, en décelant des facteurs de risque, des vulnérabilités... Ce travail réalisé conjointement par la médecine et la recherche tend à se diriger vers un concept de la médecine que l'on nomme la médecine personnalisée (ou médecine de précision).

Selon la définition de l'INCa, cette médecine a pour objectif de proposer au patient un traitement adapté aux caractéristiques de sa tumeur. [...] Elle repose actuellement sur deux types de traitements, les thérapies ciblées et l'immunothérapie spécifique. » [6]. En effet, c'est en considérant à la fois les causes génétiques chez le patient et le profil mutationnel de la tumeur, les spécificités immunologiques des types de cancer, mais également les différents autres facteurs, que nous arriverons à prendre en charge plus spécifiquement les patients et leur pathologie afin de proposer la thérapie la plus spécifique. Ces études des caractéristiques génétiques sont souvent réalisées par des approches multi-omics. Aujourd'hui, par exemple, les tumeurs peuvent être caractérisées par des séquençages génomiques, transcriptomiques, protéomiques, voire même épigénétiques et métabolomiques [7], [8], [9], [10]. De la même façon, les proportions de cellules immunitaires infiltrant plus ou moins la tumeur peuvent être appréciées par des techniques de plus en plus performantes de cytométrie en flux et de microscopie confocale. L'essor de ces techniques ces dernières années a amené les praticiens hospitaliers et les chercheurs dans les projets de recherche à générer d'incroyable quantité de données sur ces différentes caractéristiques pour les patients pris en charge [11].

C'est sur cette idée et ce besoin de développer une médecine personnalisée que l'étude Profiler a été mise en place. En effet, cette étude, coordonnée par le Pr Jean-Yves Blay et promue par le Centre Léon Berard, vise à l'établissement du profil génétique des tumeurs malignes solides et hématologiques de tous types histologiques, ceci afin d'améliorer l'orientation de la prise en charge thérapeutique des patients en fonction du profil génétique de la tumeur [12], [13]. Les données de l'étude ont par la suite intégré les données immunologiques des tumeurs de ces mêmes patients de la cohorte amenant au projet confié durant ce stage : ImmunoProfiler. L'objectif de cette étude est de déceler des potentielles corrélations entre les proportions de cellules immunitaires au sein de ces tumeurs et le profil mutationnel et génétique des patients selon plusieurs types tumoraux. Dans ce projet, nous nous sommes intéressés à la fois à des caractéristiques dites « pancancer », correspondantes à des signatures génétiques et immunologiques indépendantes du type de cancer développé, mais également à des caractéristiques spécifiques d'un type de cancer (notamment les plus représentés dans l'étude, tels que les cancers digestifs et ORL).

II. Matériel et méthodes

A. Cohorte ImmunoProfiler

Les données de cette étude ImmunoProfiler correspondent à une cohorte intégrant 492 patients de l'étude Profiler diagnostiqués pour différents types de cancer, à un stade avancé de la pathologie. Les cancers les plus représentés dans cette étude sont les cancers digestifs (n = 104 patients), ORL (n = 68 patients), SNC (n = 44 patients), sarcomes (n = 42 patients) et du pancréas (n = 41 patients). Pour chaque patient, les données cliniques sont connues, telles que l'âge au diagnostic, le sexe, le temps de survie et d'autres variables. Ces données ont été en partie récupérées à partir des dossiers patients par un algorithme appelé ConSoRe. Parmi ces patients, 325 possèdent des données génétiques pour un panel de 92 gènes fréquemment mutés dans les cancers. Ces données génétiques correspondent aux mutations missenses (SNV) et CNV pour ces 92 gènes. Dans notre étude, les mutations SNV ne correspondent uniquement qu'à des mutations exoniques et non synonymes (changement du l'acide aminé associé) de ces gènes. Ces mutations SNV ont été détectés par séquençage haut débit en utilisant la technologie NGS (Next Generation Sequencing), spécifiquement avec l'Ion Torrent PGM Sequencer de Life Technologies. Tandis que pour les CNV, une analyse par hybridation génomique comparative sur puces (aCGH) a été réalisée, avec 2 types de puces : puces Agilent 4 x 180K et puces Affymetrix CytoScanHD. Enfin, les patients ont eu un immunophénotypage des cellules immunitaires. Les données intègrent les proportions des populations totales des cellules immunitaires (par exemple LTCD4), mais également des sous-types phénotypiques de population immunitaire (par exemple LTCD4+ CD45+ CD62L-).

B. Génération de profils mutationnels

Pour la création des profils mutationnels (ou WaterfallPlot), nous avons utilisé le logiciel GenVisR [14] (package R GenVisR, version 1.34.0). Cette représentation est un excellent moyen pour représenter plusieurs patients d'une cohorte, en fonction des gènes retrouvés les plus mutés dans l'étude et de la fréquence de mutation pour les individus de l'étude (mutation burden). C'est une représentation très utilisée en oncologie, permettant de déterminer le profil de mutation (SNV et CNV) des personnes selon leur type de cancer, le type de mutations et de potentielles autres données cliniques utiles telles que l'âge, le sexe, le type histologique de la tumeur ou bien le temps de survie.

C. Analyses intégratives multi-omics


Afin de réaliser cette fouille en grande dimension et de décélérer les variables pouvant être spécifiques à un cancer ou les variables pouvant révéler un modèle plutôt pancancer, nous avons réalisé une identification des facteurs latents en utilisant le logiciel MOFA [15] [16] [17] (package R MOFA2, version 1.12.1). Ce package est capable d'intégrer plusieurs types de données (OMICS et cliniques) et de générer un modèle afin de décélérer les facteurs latents (correspondant à une combinaison des variables des différents types de données) expliquant le mieux la variance observée dans les jeux de données. Nous avons donc réalisé cette analyse MOFA sur les données contenues dans l'étude ImmunoProfiler avec ces données cliniques, immunologiques et génomiques. L'analyse MOFA a été réalisée en fixant le nombre maximum de facteurs latents à 15 (option par défaut) avec la fonction RUNMOFA du package MOFA2. De plus, les lois suivies pour la vraisemblance dans la fonction get_default_model_options du package étaient « bernouilli » pour les données génomiques (données à format binaire) et « gaussian » pour les données immunologiques log-transformées.

D. Prétraitement des données génomiques

Sur les 492 patients de l'étude ImmunoProfilier, 325 disposaient de données concernant deux types de mutation génétique sur un panel de 92 gènes : les mutations SNV et les CNV. Les gènes du panel sont des gènes sélectionnés, car connus comme fréquemment mutés dans les types de cancer apparaissant dans cette étude ImmunoProfilier. Les données de mutations SNV étaient dans un format binaire. La valeur pour un patient et pour un gène spécifique du panel pouvait donc être soit 0 si l'analyse génomique n'avait pas révélé de mutation de type SNV pour ce gène, ou bien 1 si au moins une mutation de type SNV était détectée sur ce gène. Concernant les données de mutation de type CNV, la valeur pour un patient et pour un gène spécifique pouvait être 0 si aucune mutation n'est détectée sur le gène, 1 si le gène est retrouvé amplifié chez le patient, ou -1 si le gène est retrouvé délété (totalement ou en partie) chez le patient. Afin de recevoir là aussi un format binaire pour les données de mutation de types CNV, nous avons dans notre analyse fait le parti pris de simplifier le format en ne gardant que des valeurs 0 et 1. La valeur 0 correspond donc à « pas de mutation de type CNV » et 1 à « présence d'au moins une mutation de type CNV (délétion et/ou amplification) ». Nous perdons donc de la résolution dans le type d'événement détecté, mais c'est au profit d'une meilleure puissance statistique avec plus d'événements disponibles pour chaque patient.


E. Prétraitement des données immunologiques

Sur les 492 patients de l'étude ImmunoProfilier, 482 possédaient des données pour toutes les variables immunologiques, sans données manquantes. Pour chacun de ces patients, le nombre absolu (en giga/litre) de différentes populations immunitaires a été mesuré. On comptait 30 variables correspondantes aux grandes populations immunitaires, puis 90 variables correspondantes à des sous-types phénotypiques des grandes populations immunitaires. Ces sous-populations sont des cellules immunitaires exprimant des marqueurs spécifiques. Lors de notre analyse, afin de limiter les effets des valeurs extrêmes, nous avons choisi de normaliser les valeurs des données immunologiques. Pour ce faire, nous appliquerons la fonction logarithme aux valeurs. Cela a également permis d'avoir une distribution des valeurs immunologiques suivant une loi gaussienne. Les auteurs de la technique MOFA recommandent de formater les données afin qu'elles suivent une loi normale. D'autres lois de probabilité sont possibles dans la technique MOFA (Poisson, Bernoulli), mais la gaussienne reste celle qui est la plus adaptée et rapide en tant que calcul pour la génération du modèle. Voici un exemple de distribution des valeurs pour les données immunologiques avant la transformation log et après la transformation, pour une des populations cellulaires (NK cells) :



On voit bien que les données log-transformées correspondent à une distribution de type gaussienne. Ce type de distribution est la plus adaptée pour réaliser les analyses avec MOFA.

F. Flowchart




Notre cohorte ImmunoProfilier est composée de patients provenant initialement de l'étude Profiler. Cette Profiler est une étude organisée par Jean-Yves Blay, directeur du Centre Léon Bérard et regroupe plusieurs patients de plusieurs hôpitaux. Cette étude est en cours d'inclusion de patients, c'est pourquoi le nombre de patients n'est encore pas défini. Cependant, parmi les patients déjà présents dans l'étude, 492 d'entre eux faisant partie de la CLB et pour lesquels les données immunologiques étaient disponibles ont pu être intégrés dans une cohorte fille : ImmunoProfilier. Parmi ces 492 patients, certains ne possédaient pas de données sur la localisation tumorale. Nous avons décidé de les exclure de notre analyse, car cette information est nécessaire pour la suite de notre étude. Nous avons donc 483 patients pour lesquels nous avons connaissance des données immunologiques et dont la localisation tumorale était connue. Toutefois, parmi les 483 patients, seuls 318 patients disposaient des données de mutation pour les CNV et les SNV, 60 patients avec uniquement des données pour les mutations SNV, 17 patients avec uniquement des données pour les CNV et 88 patients pour lesquels aucune donnée génétique n'était disponible. Enfin, on comptait 104 patients atteints de cancer digestif et 68 patients atteints de cancer ORL, repartis parmi ces différents groupes.

III. Résultats

A. Waterfallplot


1. Profil mutationnel général



Notre première approche pour décrire les données disponibles via la cohorte ImmunoProfiler a été d'utiliser les données de mutations SNV et CNV pour l'ensemble des patients, indépendamment de leur type de cancer afin de réaliser un waterfall plot. Cela nous a permis, dans un premier temps, d'obtenir le profil mutationnel pour les 395 patients d'ImmunoProfiler disposant de données génétiques. Nous avons ici une représentation des 395 patients selon les 45 gènes les plus mutés sur les 92 gènes du panel testé. De nombreux patients présentaient des données manquantes pour plusieurs de ces gènes (représenté en gris), ce qui est important à différencier des patients ne possédant pas de mutation pour ces gènes (représenté en blanc). Lorsque l'on considère tous les cancers, *TP53* et *KRAS* sont les gènes se caractérisant le plus par des mutations de type SNV, plus précisément des mutations de type missense (représentées en orange). De façon surprenante, on constate également la présence d'au moins 3 patients hypermutés pour une grande partie des gènes du panel. En revanche, notons que ces mutations pour ces deux patients ne semblent être qu'exclusivement de type SNV. Chez tous les patients de la cohorte, tous cancers confondus, le gène présentant le plus de CNV de type « gain/amplification » est le gène *SRC*, tandis que les gènes les plus délétés sont *CDKN2A* puis, à nouveau, *TP53* en 2^e position. Ce sont des gènes qui ont été auparavant démontrés comme impactant de manière significative l'apparition des cancers. La protéine p53, dérivant du gène *TP53*, est la protéine « gardienne du génome » et régulant l'activation de la réparation de l'ADN endommagé. *SRC* est un gène régulateur de la prolifération cellulaire. Un gain pour ce gène résultera en une prolifération incontrôlée des cellules mutées, typique des cellules cancéreuses. Il n'est donc pas étonnant de retrouver tous ces gènes mutés chez les patients composant notre cohorte. Cela fournit toutefois une vision globale des données génétiques pour les patients de cette cohorte. Il serait maintenant intéressant de regarder, pour les cancers les plus représentés dans ce jeu de données (cancers digestifs et cancers ORL), les gènes et les mutations associés les plus fréquentes afin d'établir un profil mutationnel spécifique à ces types de cancer.


2. Profil mutationnel spécifique

a. Cancers digestifs



Nous avons ci-dessus le profil mutationnel des patients atteints de cancer digestif au sein de notre cohorte ImmunoProfiler. On observe que les gènes avec le plus de mutations de type SNV missense correspondent aux gènes *TP53*, *KRAS* et *APC*. Comme vu précédemment, le gène *TP53* est aussi celui le plus muté pour tous les types de cancer confondus. On peut donc dire que *TP53* n'est pas un gène muté spécifiquement dans le cas des cancers digestifs, mais correspond plutôt à un gène qui sera fréquemment muté dans l'ensemble des cancers. En revanche, les mutations sur les gènes *KRAS* et *APC* sont connues pour être des initiateurs du développement des cancers digestifs, notamment les cancers colorectaux. Ces gènes ne sont pas retrouvés dans les premiers gènes les plus mutés lorsque l'on regarde le Waterfall Plot pour tous les cancers confondus. *KRAS* et *APC* pourraient donc être considérés comme des gènes marqueurs et spécifiquement mutés dans le cas des cancers digestifs dans cette cohorte. De plus, on retrouve là aussi l'amplification du gène *SRC*, mais nous avons vu précédemment que c'était également commun dans de nombreux autres cancers. Enfin, le gène *CDKN2A* est très souvent délété chez les patients atteints de cancer digestif, mais comme vu précédemment, cela semble être une mutation pour ce gène aussi très répandu pour les autres types de cancer. On peut dire que ces gènes sont spécifiquement mutés chez les patients ayant un cancer de type digestif dans notre cohorte ImmunoProfiler. Dans le cadre d'une démarche de médecine personnalisée, ils pourraient être de bonnes cibles thérapeutiques pour cibler spécifiquement les cellules cancéreuses dérivant de cancers digestifs pour les patients de cette cohorte

b. Cancers ORL




Voici maintenant le profil mutationnel des patients de la cohorte disposant d'un cancer de type ORL. Comme pour le cas des cancers digestifs, nous retrouvons le gène *TP53* avec le plus fréquemment des mutations de type missense. Aucun autre gène ne semble être très fortement impacté par ce type de mutations. En revanche, on retrouve les gènes *MST1R* et *VHL* très fréquemment délétés, tandis que les gènes *PIK3CA* et *ATR* très fréquemment avec un gain de ces gènes. *VHL* est un gène suppresseur de tumeur et est impliqué dans la croissance et la division cellulaire. Une délétion de ce gène est donc délétère pour l'homéostasie cellulaire et promeut l'apparition de cellules cancéreuses. Ce gène semble être spécifiquement plus muté chez les patients de notre cohorte disposant d'un cancer ORL. De manière similaire, le gène retrouvé le plus amplifié chez ces patients atteints de cancer ORL est le gène *PIK3CA*. Ce gène est un important régulateur du métabolisme et de la croissance cellulaire. Comme nous le montre notre analyse sur l'ensemble des patients de la cohorte, pour tous cancers confondus, *VHL* et *PIK3CA* sont des gènes faisant partie des gènes fréquemment mutés dans l'ensemble des cancers. Cependant, il semble que pour les personnes atteintes de cancer ORL, il soit plus fréquent de retrouver ces gènes spécifiquement mutés comparé à l'entièreté des cancers pris dans leur globalité.

Grâce à ces Waterfall plots, nous avons pu avoir une vision globale des données génétiques pour chaque patient de la cohorte et décrire spécifiquement pour les patients d'une catégorie de cancer, en particulier les gènes et les types de mutations les plus fréquemment associés. Nous avons montré que certains gènes, très fréquemment mutés dans les cancers de types digestifs, tels que *KRAS* et *APC*, pourraient tout à fait être des cibles thérapeutiques sur lesquelles agir pour le traitement des patients atteints de ce type de cancer.

Afin de décrire au mieux cette cohorte ImmunoProfiler, une seconde approche serait d'intégrer en plus des données génétiques les données immunologiques de chaque patient. Pour réaliser cela, nous avons procédé à une analyse multi-omics, appelée MOFA.

B. Multi-Omics Factor Analysis

1. Caractéristiques du modèle entraîné et facteurs latents associés



L'analyse MOFA repose sur l'entraînement d'un modèle statistique Bayésien. Par plusieurs itérations successives, le modèle va identifier les variables dans le jeu de données qui partagent une structure de corrélation similaire et expliquant le mieux la variance des données observées. Comme on pourrait le faire dans une certaine mesure avec les axes d'une ACP, ces différentes variables explicatives vont être regroupées ensemble selon un certain nombre de facteurs latents. En revanche, contrairement à l'ACP, quelques-unes des caractéristiques de l'analyse MOFA sont qu'il y a un système interne de gestion des données manquantes et que les facteurs latents peuvent être redondants entre eux en partageant parfois les mêmes variables. Par défaut, l'analyse MOFA tente de trouver 15 facteurs latents pour expliquer la variabilité retrouvée dans le jeu de données. Pour notre cohorte ImmunoProfiler, nous avons 31 variables de données immunologiques (représentant les différentes populations de cellule) et 163 variables génomiques (correspondant aux données de mutation de type SNV et CNV pour un panel de gènes). Pour certains patients, quelques-unes de ces données sont manquantes (en gris), mais MOFA est capable de gérer cela. De plus, nous avons précisé, lors de la construction du modèle, la présence de groupes de patients correspondant aux types de cancer pour les patients. Nous avons ainsi plusieurs groupes ou panels de patients répartis selon leur type de cancer et avec à la fois des données génétiques et immunologiques. Le modèle construit par MOFA prévoit 15 facteurs latents par défaut, cependant le modèle peut choisir de représenter moins de facteurs latents si certains d'entre eux sont trop fortement corrélés entre eux. Cela garantit que tous les facteurs ne présentent pas une trop forte corrélation entre eux et qu'ils puissent chacun expliquer une part différente de la variance des données (figure de la variance par facteurs). Notre modèle ici nous a permis d'expliquer globalement 60 % de la variance totale présente dans notre jeu de données, cependant cette proportion varie selon la catégorie de cancer considérée et le type de données (génétique et immunologique). Lorsque l'on regarde la variance expliquée par chacun de ces facteurs, on constate que chaque facteur semble expliquer spécifiquement la variance d'un seul type de donnée : génomique (G) ou immunologique (I). Par exemple, le facteur 1 explique plus de 15 % de la variance totale des données génomiques, mais pas immunologiques. À l'inverse, le facteur 2 lui explique exclusivement plus de 15 % de la variance des données immunologiques. Au-delà du facteur 7, la variance cumulée des données immunologiques se stabilisait. Rajouter des facteurs latents ne permet que très peu d'expliquer davantage de variance. Ce n'est pas le cas pour les données génomiques, où, à partir du facteur 7 et à chaque nouveau facteur latent, un peu plus de variance génomique est expliquée. Au-delà du facteur 10, la variance cumulée expliquée pour les données génétiques et immunologiques atteint une phase de plateau, où l'ajout de facteur latent ne contribue que très peu à expliquer la variance restante dans les données.

Ainsi, nous avons construit avec MOFA un modèle qui permet, à partir d'environ 200 variables génomiques et immunologiques initiales, de trouver 15 facteurs latents permettant d'expliquer plus de 60 % de la variance totale contenue dans les données génomiques et immunologiques. Nous allons maintenant caractériser un peu plus ces facteurs latents et les variables qui contribuent le plus à ces facteurs.

2. Caractérisation des facteurs latents




Figure 7 : Distribution des valeurs des facteurs latents. Représentation des valeurs prises par les 10 premiers facteurs latents en fonction des différents types de cancer au sein de la cohorte ImmunoProfiler. Chaque point correspond à un patient. Les valeurs ont été centrées entre elles et alignées sur 0, afin d'observer facilement si l'une des distributions de l'un des groupes est différente des autres.

Pour chaque facteur latent identifié, on représente les valeurs prises pour chaque individu selon leur groupe d'appartenance, correspondant à l'organe touché par le cancer. On constate que toutes les valeurs sont centrées sur 0, car nous avons utilisé une fonctionnalité de MOFA pour mettre à la même échelle toutes les données, permettant une comparaison plus facile des variables entre elles. De plus, on peut voir que, selon le facteur considéré, la plage des valeurs prises par les facteurs latents pour chaque individu est plutôt variable. Par exemple, la variabilité des valeurs pour le facteur latent n° 2 est plus importante que celle prise par le facteur 1. Cela peut en partie s'expliquer par le fait que, comme évoqué dans la figure précédente, le facteur latent 2 explique préférentiellement les données immunologiques, tandis que le facteur 1, plutôt les données génétiques. Les données immunologiques étant des données continues, contrairement aux données de mutations qui sont des données binaires, cela se traduit sur le graphe des valeurs prises pour chaque facteur par une distribution plus étalée dans le facteur 2. On constate également qu'aucun des groupes de patients au sein d'un même facteur latent ne diffère dans la forme des violin plots. Au sein d'un facteur latent, la représentation des groupes est plutôt homogène. Cela est un premier indice nous indiquant qu'il ne semble pas y avoir de facteur latent discriminant une catégorie de cancer particulière et que donc les variables disponibles dans notre cohorte ImmunoProfiler ne permettent pas d'établir un lien entre nos données immunologiques, mutationnelles et les types tumoraux.

Pour chacun de ces facteurs latents, il est maintenant possible de regarder les variables explicatives qui ont le plus de poids (en valeur absolue) dans la variance expliquée par ce facteur. On peut donc ainsi avoir une liste des meilleurs contributeurs pour chaque facteur latent (dans notre étude, ce sont les gènes mutés et/ou les populations immunitaires), expliquant le mieux la variance au sein du jeu de données. Comme nous regardons les variables ayant un maximum de poids en valeur absolue, un signe (plus ou moins) est associé à chaque variable. Dans les figures ci-dessus (Panel de gauche), on peut voir les 30 meilleures variables contributrices pour les facteurs latents 1 et 2. Le facteur latent n° 1 étant celui capturant le mieux la variabilité des données génomiques, les variables ayant un poids le plus important correspondent donc à des types de mutation. Ici, on observe que ce sont toutes des mutations de type CNV, avec la mutation sur le gène *CDKN2A* contribuant le plus à l'explication de la variance dans ce facteur latent. Il est possible d'aller plus loin dans l'analyse et de réaliser une heatmap, où les gènes qui auront des données de mutation les plus proches/similaires parmi tous les patients peuvent clusteriser ensemble. Par exemple, les gènes *CDKN2A*, *TEK*, *SMARCA2* et *JAK2* qui présentent une mutation de type CNV auront plus souvent tendance à être mutés ensemble pour les patients de notre cohorte ImmunoProfiler. Pour le facteur 2, capturant le mieux la variance des données immunologiques, ce sont des populations immunitaires. Pour ce facteur latent, la variable immunologique expliquant le mieux la variance capturée par ce facteur 2 est la population des LTCD4 naifs. Ici aussi, il est également possible de réaliser une heatmap des patients se ressemblant le plus aux valeurs prises pour ces top variables dans ce facteur latent. On constate pour les populations immunitaires que les grandes catégories de cellules immunitaires se regroupent entre elles avec les groupes des lymphocytes (LTCD4/LTCD8), des monocytes (ncmono, clMono, Monototal, inflmono) et des cellules dendritiques (cDC1, cDC2, pDC). De façon surprenante, nous retrouvons les résultats réalisés lors d'analyses préliminaires sur ces données immunologiques. Ces précédentes analyses réalisaient une ACP sur l'entièreté des variables immunologiques de la cohorte de patients ImmunoProfiler, et mettaient en évidence, sur les principaux axes de l'ACP, la présence de ces mêmes clusters de variables. Cela est à un certain point rassurant sur la fiabilité de la démarche et des résultats obtenus avec le modèle généré par MOFA.

Nous avons donc, avec le modèle MOFA, 15 facteurs latents, capturant une grande part de la variance totale du jeu de données de la cohorte, et pour lesquels nous pouvons très facilement accéder à l'information des variables participant au mieux à expliquer la variabilité des données, qu'elles soient génomiques ou immunologiques. Afin de mieux décrire notre cohorte de patients et de révéler des possibles liens entre les différents types de données et le type de cancer de chacun des patients, nous allons maintenant voir comment mieux caractériser les individus selon les différentes valeurs obtenues pour chacun de ces facteurs latents identifiés.

3. Clusterisation des patients et caractérisation des clusters trouvés




Figure 10 : Clusters et UMAP. **A.** Graphique Elbow montrant l'inertie en fonction du nombre de classe. Le point bleu représente le nombre de clusters (N = 9 clusters) associé à un fort saut dans l'inertie. **B.** Dendrogramme des patients clusterisé en 9 classes selon les valeurs de chacun des patients pour les 15 facteurs latents obtenus. **C.** Projection UMAP de chaque patient, colorée selon leur cluster d'appartenance. **D.** Projection UMAP de chaque patient coloré selon leur type de cancer. **E.** Barplot quantifiant le pourcentage de patients appartenant à chaque cluster par groupe, autrement dit le type de cancer (pct_by_organ). Peu, voire aucun des groupes n'est surreprésenté dans un des clusters. **F.** Caractérisation de chaque cluster de patients par la moyenne des valeurs obtenues pour les 15 facteurs latents. Certains clusters sont mieux caractérisés par certains facteurs latents.

Les valeurs des 15 facteurs obtenues pour chaque patient peuvent être utilisées pour réaliser un clustering hiérarchique ascendant afin de regrouper les 483 patients les plus similaires par rapport aux valeurs obtenues pour ces 15 facteurs latents. Cette technique va calculer la distance moyenne (distance Euclidienne) entre chaque patient sur les 15 axes correspondant aux 15 facteurs latents trouvés par MOFA. Grâce au graphique « elbow », on constate un saut d'inertie important lorsque l'on a 9 clusters (ou classes). Ces classes sont visualisables sur le dendrogramme suivant, regroupant les patients en plusieurs clusters distincts. Le calcul du dendrogramme par la méthode Ward permet notamment de « minimiser l'inertie intra-classe et de maximiser l'inertie inter-classe afin d'obtenir des classes les plus homogènes possibles » [18]. Les patients sont donc maintenant caractérisables par un type de cluster qui repose sur la similarité des patients pour les valeurs de ces 15 facteurs latents. Ces 9 clusters ont été ensuite utilisés pour réaliser un mapping UMAP2 sur tous les patients de la cohorte en colorant spécifiquement les patients selon leur cluster d'appartenance. On constate qu'aucun des points (patients) ne semble se regrouper selon le type de cluster. Hormis certains petits clusters très spécifiques, tels que les clusters 8 et 9, l'ensemble semble globalement plutôt désordonné, sans réel regroupement. De la même manière, une seconde représentation du UMAP est possible, en conservant les différents types de cluster selon la couleur, mais en les séparant à chaque fois selon le type d'organe atteint par le cancer pour chaque patient. Nous pouvons voir que globalement, là aussi, aucun des clusters n'est particulièrement enrichi pour un des types de cancer. Par la suite, nous avons quantifié ces représentations en mesurant le pourcentage d'apparition de ces clusters parmi les différents types de cancer. On constate bien ici qu'il n'y a pas de valeur quantitativement plus élevée pour l'un des types tumoraux au sein de chaque cluster. On remarque toutefois que l'on retrouve fréquemment le cluster 1 de patients dans de nombreux et divers types de cancer. D'autres clusters de patients sont moins fréquents, tels que par exemple les clusters 8 et 9. En revanche, aucun d'eux ne semble spécifique pour un type de cancer. Afin de mieux caractériser ces clusters d'appartenance, on a regardé ensuite pour chacun de ces clusters leur composition selon les facteurs latents. Ainsi, on constate que le cluster 1 que l'on retrouve dans la plupart des patients, tous cancers confondus, se traduit par une faible caractérisation par l'ensemble des 15 facteurs latents. Ce cluster 1 ne distingue finalement pas beaucoup les patients entre eux. En revanche, d'autres clusters, tels que le cluster 8 par exemple, sont très bien caractérisés par le facteur latent 5. De la même manière, le cluster 2 semble légèrement plus enrichi par des patients présentant un cancer lié aux voies urinaires, et ce même cluster semble être plutôt bien caractérisé par le facteur latent numéro 4. En analysant la composition du facteur latent 4 et les variables associées présentant un fort poids sur celui-ci, cela pourrait correspondre à des cibles thérapeutiques intéressantes pour traiter ce type de cancer. Toutefois, il reste assez compliqué de réellement définir un cluster spécifique pour un type de cancer spécifique. Cela nous amène donc à penser le cancer sous un modèle dit « pancancer » où, au final, les gènes mutés et la proportion des populations immunes retrouvées chez le patient ne seront pas si différentes si l'on considère un type de cancer par rapport à un autre.

Notre analyse multi-omics avec la méthode MOFA nous a permis donc de réduire la dimensionnalité de notre jeu de données qui était initialement de plus de 194 variables (31 variables immunologiques, 163 variables génétiques, plusieurs dizaines de variables cliniques (âge, sexe, temps de suivi... etc.), à 15 facteurs maximum. En plus de considérablement réduire la complexité du nombre de données disponibles, ces facteurs latents permettent d'identifier les variables contribuant le plus à la variabilité des données, selon leur type, c'est-à-dire immunologiques ou génétiques. Ces variables les plus contributrices à la variance totale des données sont des informations précieuses pour les biologistes, par la suite, pour interpréter les différentes variables retrouvées. On a ainsi pu montrer avec nos analyses qu'il ne semblait pas y avoir de liens entre les différentes populations immunitaires et les altérations des gènes permettant de spécifiquement discriminer les patients selon leurs types de cancer. Cela nous amène à penser le cancer comme un modèle pancancer, pour lequel les caractéristiques immunologiques et mutationnelles retrouvées pour les différents patients sont, dans une certaine mesure, communes à tous les types de cancer.

IV. Discussion

Avec l'essor, ces dernières années, des nombreuses analyses bioinformatiques et des méthodes OMICS telles que la génomique, transcriptomique, protéomique, métabolomique... etc., nous avons aujourd'hui accumulé de très grandes quantités de données biologiques répondant à diverses problématiques. Un des enjeux dans les prochaines années sera de savoir intégrer toutes ces données OMICS ensemble afin de répondre à des problématiques biologiques encore plus complexes. Des travaux tels que Hoadley, Katherine A. et al. [19] ont déjà réussi à montrer qu'en assimilant les différentes strates des données omics, nous sommes aujourd'hui capables de caractériser plusieurs types de cancer sur ces différents plans moléculaires. Cela ouvre la voie pour la découverte de potentielles nouvelles cibles thérapeutiques et des thérapies ciblées conçues sur-mesure sur le profil moléculaire du patient. Cette idée de médecine personnalisée et de meilleure caractérisation des cancers sont atteignables par des analyses factorielles [20] comme celles proposées par MOFA. De manière non supervisée et sans a priori, il est ainsi possible de caractériser les variables expliquant le plus la variance de l'ensemble des données. On peut ainsi réduire la dimensionnalité du problème, s'expliquant initialement avec plusieurs dizaines voire centaines de variables explicatives, en quelques facteurs seulement. C'est dans ce cadre de fouille de données en grande dimension que cette étude s'inscrit. L'analyse factorielle, comme celle réalisée par MOFA, est une méthode d'analyse des données visant à expliquer la même quantité de variance qui est incluse dans les variables initiales avec un nombre restreint de facteurs latents. Cette technique va chercher à expliquer la variabilité des données observées en réduisant la dimension du problème et en proposant des collections de variables (facteurs latents) expliquant le mieux la variabilité des données. Cette méthode est capable de gérer les données manquantes pour certains des individus. Celle-ci la rend donc particulièrement bien adaptée pour l'étude de grosse cohorte où les données manquantes sont fréquentes. De plus, l'analyse MOFA donne l'opportunité aux utilisateurs d'utiliser divers types de données tout en précisant la structure de celles-ci. En effet, dans notre analyse, nous avons par exemple précisé que nos données de mutation respectaient un format binaire et que la loi de probabilité suivie correspondait à une loi de Bernoulli. Pour les données immunologiques, les données étaient continues et nous avons précisé que la loi de probabilité associée était une loi binomiale. Spécifier les distributions suivies par les différentes données permet d'avoir une vraisemblance calculée par le modèle cohérente avec les données observées. Enfin, l'analyse MOFA permet de préciser l'existence de groupes au sein des données. Dans notre analyse MOFA, nous avons construit un modèle prenant en compte la catégorie du cancer pour chaque patient, représentée par la variable « organ ». Il est préférable que le modèle MOFA considère l'information des groupes de cancer pour trouver les différents facteurs latents. En effet, cela permet de voir quelles sont les variables spécifiques d'un groupe précis et quelles sont communes entre tous les groupes. Cela permet donc de voir à la fois les variables plutôt pancancer et les variables plutôt spécifiques à un type de cancer particulier. De plus, par soucis de temps et de concentration des efforts, nous avons préféré travailler sur un seul modèle MOFA prenant en compte le type d'organe touché par le cancer, plutôt qu'une analyse MOFA pour un type de cancer spécifique. Cependant, avec plus de temps, il serait pertinent de poursuivre les analyses avec une analyse MOFA en ne prenant pas en compte les différents groupes de cancer. Cela permettrait d'avoir un second modèle MOFA où le type d'organe touché par le cancer pour chaque patient est pris en compte et de voir si des informations complémentaires peuvent être obtenues. De plus, une analyse MOFA sur chaque type de cancer serait intéressante à réaliser, ou à défaut sur les types de cancer les plus représentés dans l'étude (digestifs et ORL). Cela permettrait de compléter la vision pan cancer développée dans notre étude.

Afin d'obtenir une puissance statistique plus élevée, nous avons lors du traitement des données génomiques fait le choix de formater les données sur les CNV afin de combiner les CNV de type « délétion » avec les CNV de type « amplification ». Ainsi, nous avons eu plus de données pour les données de CNV, mais nous perdons un peu en résolution, car l'information « gain » ou « délétion » pour les CNV sont confondues et ne sont plus prises en compte dans l'établissement des facteurs latents. Néanmoins, il reste toujours possible de remonter au type du CNV en analysant a posteriori les données initiales où le type de CNV (amplification ou délétion) est spécifié pour chaque patient.

V. Conclusion

A. Réponse à la problématique

L'objectif de ce projet était de décrire les données génétiques et immunologiques de l'ensemble des patients de la cohorte ImmunoProfilier en réalisant des profils mutationnels et des statistiques descriptives des patients. Il était demandé de travailler sur la normalisation des données, notamment celles immunologiques, afin de pouvoir tirer le maximum d'information de ces données. C'est ce que nous avons fait en appliquant une transformation logarithmique afin de pleinement voir les différences de populations immunitaires et en atténuant l'influence des valeurs extrêmes. Enfin, il était demandé, en intégrant les jeux de données OMICS (immunologiques, génomiques et cliniques) de chaque patient, d'explorer les corrélations existantes et de classer ces patients via des méthodes de clustering non supervisé. En intégrant toutes les données OMICS et cliniques mises à disposition dans l'étude ImmunoProfilier, notre analyse ne semble pas mettre en évidence des critères, tant génomique qu'immunologiques, qui soient spécifiques à un type de cancer. Cela nous amène donc à réfléchir plutôt à un modèle de la biologie du cancer dit « pancancer », où les patterns, les signatures biologiques et les mécanismes moléculaires sont conservés à travers les différents types de cancers. Notre étude, sur cette cohorte ne montre donc pas de spécificité ou de lien entre les quantités des populations immunes, les altérations moléculaires et les types tumoraux des patients.

B. Ouverture

1. Recherche de clusters à susceptibilité

Nous avons pu regrouper les patients de cette cohorte ImmunoProfilier en différents clusters selon leurs données immunologiques et leurs données génétiques. Une analyse intéressante et pertinente serait de réaliser une étude de la survie des patients, via une courbe de Kaplan-Meier par exemple, en regardant spécifiquement la survie pour les différents clusters réalisés via la méthode MOFA, et observer si une des clusters est plus à risque, ou au contraire mieux protégé que les autres. Ainsi, en mesurant les variables contenues dans les facteurs latents correspondant aux clusters plus ou moins à risque, cela pourrait être un moyen de catégoriser des patients lors d'un diagnostic, en les assignant à un cluster et d'adapter le traitement selon le cluster d'appartenance. Par exemple, un cluster spécifique pourrait regrouper plutôt des patients avec certaine susceptibilité ou une survie moins favorable. Cela serait un bon moyen d'aide à la décision que le corps médical pourrait avoir à sa disposition pour orienter au mieux la prise en charge de la pathologie et avoir une médecine plus personnalisée selon les caractéristiques immunologiques et génétiques du patient.

2. Machine Learning

L'analyse factorielle réalisée avec MOFA fait partie des méthodes d'analyse dites « non supervisées ». Pour poursuivre cette étude ImmunoProfilier, il serait totalement pertinent de réaliser des analyses appliquant une méthode dite « supervisée ». C'est le principe du machine learning. Étant donné le grand nombre de variables que les données peuvent être, il serait pertinente d'utiliser des méthodes de régression pénalisée telles que la méthode Lasso ou Ridge [21]. La méthode Lasso permettrait de sélectionner les variables les plus intéressantes pour modéliser les données tout en réduisant le grand nombre de variables. De plus, les variables importantes identifiées avec la méthode MOFA pourraient tout à fait permettre de sélectionner les variables importantes à considérer dans le modèle supervisé. Cela permettrait d'initialement de réduire la dimensionalité du problème et de ne prendre que certaines variables explicatives qui semblent avoir du sens pour expliquer la variance dans les autres analyses, telles que MOFA.

Bibliography

1. Ferlay, J., Ervik, M., Lam, F., Laversanne, M., Colombet, M., Mery, L., Piñeros, M., Znaor, A., Soerjomataram, I., & Bray, F. (2024). Global Cancer Observatory: Cancer Today. Retrieved from <https://gco.iarc.who.int/today>
2. Fondation pour la recherche sur le cancer. (n.d.). Cancer : les facteurs de risque. Retrieved from <https://www.fondation-arc.org/cancer/facteurs-risque-cancer>
3. Sebolt-Leopold, J., Dudley, D., Herrera, R., et al. (1999). Blockade of the MAP kinase pathway suppresses growth of colon tumors in vivo. Retrieved from <https://doi.org/10.1038/10533>
4. Alsaab, H. O., Sau, S., Alzhrani, R., Tatiparti, K., Bhise, K., Kashaw, S. K., & Iyer, A. K. (2017). PD-1 and PD-L1 checkpoint signaling inhibition for cancer immunotherapy: Mechanism, combinations, and clinical outcome. Retrieved from <https://doi.org/10.3389/fphar.2017.00561>
5. Han, Y., Liu, D., & Li, L. (2020). PD-1/PD-L1 pathway: Current researches in cancer. Retrieved from <https://pubmed.ncbi.nlm.nih.gov/32266087>
6. Ifrah, N. (n.d.). La médecine de précision. Retrieved from <https://www.e-cancer.fr/Comprendre-prevenir-depister/Comprendre-la-recherche/La-medecine-de-precision>
7. Ghandi, M., Huang, F. W., Jané-Valbuena, J., et al. (2019). Next-generation characterization of the Cancer Cell Line Encyclopedia. Retrieved from <https://doi.org/10.1038/s41586-019-1186-3>
8. Charoentong, P., Finotello, F., Angelova, M., Mayer, C., Efremova, M., Rieder, D., ... & Trajanoski, Z. (2017). Pan-cancer immunogenomic analyses reveal genotype-immunophenotype relationships and predictors of response to checkpoint blockade. Retrieved from <https://doi.org/10.1016/j.celrep.2016.12.019>
9. Raufaste-Cazavieille, V., Santiago, R., & Droit, A. (2022). Multi-omics analysis: Paving the path toward achieving precision medicine in cancer treatment and immuno-oncology. Retrieved from <https://doi.org/10.3389/fmolb.2022.962743>
10. Heo, Y. J., Hwa, C., Lee, G. H., Park, J. M., & An, J. Y. (2021). Integrative multi-omics approaches in cancer research: From biological networks to clinical subtypes. Retrieved from <https://doi.org/10.14348/molcells.2021.0042>
11. Jiang, P., Sinha, S., Aldape, K., et al. (2022). Big data in basic and translational cancer research. Retrieved from <https://doi.org/10.1038/s41568-022-00502-0>
12. National Cancer Institute. (n.d.). Program to Establish the Genetic and Immunologic Profile of Patient's Tumor for All Types of Advanced Cancer (PROFILER). Retrieved from <https://clinicaltrials.gov/study/NCT01774409>
13. Centre Léon Bérard. (2016). Protocole Profiler. Retrieved from <https://www.centreleonberard.fr/sites/default/files/2018-08/profiler-protocole-webcleon-berard.pdf>

14. Skidmore, Z. L., Wagner, A. H., Lesurf, R., Campbell, K. M., Kunisaki, J., Griffith, O. L., & Griffith, M. (2016). GenVisR: Genomic Visualizations in R. Retrieved from <https://doi.org/10.1093/bioinformatics/btw325>
15. Argelaguet, R., Velten, B., Arnol, D., Dietrich, S., Zenz, T., Marioni, J. C., Buettner, F., Huber, W., & Stegle, O. (2018). Multi-omics factor analysis—a framework for unsupervised integration of multi-omics data sets. Retrieved from <https://doi.org/10.15252/msb.20178124>
16. Argelaguet, R., Arnol, D., Bredikhin, D., Deloro, Y., Velten, B., Marioni, J. C., & Stegle, O. (n.d.). MOFA+: A statistical framework for comprehensive integration of multi-modal single-cell data. Retrieved from <https://doi.org/10.1186/s13059-020-02015-1>
17. Velten, B., Braunger, J. M., Arnol, D., Argelaguet, R., & Stegle, O. (2020). Identifying temporal and spatial patterns of variation from multi-modal data using MEFISTO. Retrieved from <https://doi.org/10.1038/s41592-021-01343-9>
18. Barnier, J., Biaudet, J., Briatte, F., Bouchet-Valat, M., Gallic, E., Giraud, F., Gombin, J., Kauffmann, M., Lalanne, C., & Larmarange, J., & Robette, N. (n.d.). GitHub: Introduction à l'analyse d'enquêtes avec R et RStudio. Retrieved from <https://larmarange.github.io/analyse-R/classification-ascendante-hierarchique.html>
19. Hoadley, K. A., Yau, C., Hinoue, T., Wolf, D. M., Lazar, A. J., Drill, E., Shen, R., Taylor, A. M., Cherniack, A. D., Thorsson, V., Akbani, R., Bowlby, R., Wong, C. K., Wiznerowicz, M., Sanchez-Vega, F., Robertson, A. G., Schneider, B. G., Lawrence, M. S., Noushmehr, H., Malta, T. M., ... Laird, P. W. (2018). Cell-of-origin patterns dominate the molecular classification of 10,000 tumors from 33 types of cancer. Retrieved from <https://doi.org/10.1016/j.cell.2018.03.022>
20. Drouet, Y., Bonadona, V., Gargano, E., Kardous, E., Chauvin, H., Girerd-Genessay, I., Dussart, S., Handallou, S., & Lasset, C. (2017). Classification des familles de type sein-ovaire sans mutation constitutionnelle de BRCA1/2 identifiée, pour le niveau de risque de cancer du sein : apport d'une stratégie d'évaluation multicritères s'appuyant sur une méthode d'analyse factorielle. Retrieved from <https://doi.org/10.1016/j.respe.2017.04.039>
21. Jacquemin, J., Drouet, Y., Le Guevelou, J., Servagi-Vernat, S., & Thariat, J. (2021). Modélisation de la survie de patients atteints d'un cancer anaplasique de la thyroïde par régression pénalisée LASSO. Retrieved from <https://doi.org/10.1016/j.respe.2021.04.081>